ENM-383 Yapay Zeka Temelleri Dersi Proje Ödevi

Haticesu Yılancı 23112020054
Seymen Can Arpaçay 23112020048
Sude Karaduman 22112020016

ENM 383 BİLİMSEL ARAŞTIRMA TEKNİKLERİ PROJE ÖDEVİ

GAZİ ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
ENDÜSTRİ MÜHENDİSLİĞİ

ARALIK 202

Özet

Bu çalışmada, geçmiş kaza kayıtlarından elde edilen bir veri seti kullanılarak bir kazada ortaya çıkan en ağır yaralanma seviyesinin makine öğrenmesi yöntemleri ile tahmin edilmesi amaçlanmıştır. Çalışma, denetimli öğrenme kapsamında çok sınıflı bir sınıflandırma problemi olarak ele alınmıştır ve Random Forest algoritmasından yararlanılmıştır. Bu kapsamda veri seti üzerinde veri ön işleme adımları uygulanmış; kategorik değişkenler sayısal formata dönüştürülmüş ve uygun özellik seçimi gerçekleştirilmiştir. Ardından Random Forest başta olmak üzere çeşitli makine öğrenmesi algoritmaları eğitilmiş ve performansları karşılaştırılmıştır. Model performansları doğruluk (accuracy), F1-skoru ve karışıklık matrisi gibi ölçütler kullanılarak değerlendirilmiştir. Elde edilen sonuçlar, makine öğrenmesi yöntemlerinin yaralanma seviyesinin tahmininde etkili bir şekilde kullanılabileceğini göstermektedir. Bu çalışma, kaza verilerinin analizine veri temelli bir yaklaşım sunmakta ve riskli durumların önceden tespit edilmesine katkı sağlamayı amaçlamaktadır.

Anahtar Kelimeler: Trafik kazaları, makine öğrenmesi, sınıflandırma, yaralanma seviyesi, Random Forest

Abstract

In this study, a dataset obtained from historical traffic accident records is used to predict the most severe injury level resulting from a crash by means of machine learning methods. The problem is formulated as a multi-class classification task within the scope of supervised learning, and the Random Forest algorithm is primarily employed. Data preprocessing steps are applied to the dataset, including the transformation of categorical variables into numerical formats and the selection of relevant features. Subsequently, Random Forest and several other machine learning algorithms are trained and their performances are compared. Model performances are evaluated using metrics such as accuracy, F1-score, and the confusion matrix. The results indicate that machine learning methods can be effectively utilized to predict injury severity. This study provides a data-driven approach to traffic accident analysis and aims to contribute to the early identification of risky situations.

Keywords: Traffic accidents, machine learning, classification, injury severity, Random Fores

İÇİNDEKİLER

Sayfa

1.GİRİŞ 1

1.1 Problemin Tanımı 1

1.2. Çalışmanın Amacı ve Önemi 1

1.3. Çalışmanın Kapsamı ve Katkıları 1

2.CRISP-DM Metodolojisi 2

2.1. Problemi Anlama 3

2.2. Veriyi Anlama 3

2.3. Veriyi Hazırlama 4

2.4. Modelleme 4

2.5. Değerlendirme 4

2.6. Uygulamaya Alma 4

3.UYGULAMA 4

3.1. İş Anlayışı (Business Understanding) 4

3.1.1. Problemin Tanımlanması 4

3.1.2. Niteliklerin Belirlenmesi 5

3.1.3. Verilerin Toplanması 6

3.1.4. Veri Setinin Yüklenmesi 7

3.2. Veriyi Anlama (Data Understanding) 8

3.2.1. Tanımlayıcı İstatistikler 8

3.2.2. Pasta Grafiği Oluşturulması 11

3.2.3. Histogramların Oluşturulması 15

3.2.4 Aykırı Değer Analizi 16

3.2.5 Korelasyon Analizi 17

3.3 Veriyi Hazırlama 18

3.3.1 Kategorik Verilerin Dönüştürülmesi 18

3.3.2 Bağımlı ve Bağımsız Verilerin Gruplara Ayrılması 19

3.3.3 Öznitelik Ölçeklendirme 20

3.3.4 Özellik Çıkarımı ve Seçimi 20

3.3.5 Eğitim ve Test Veri Setlerinin Oluşturulması 21

3.4 Makine Öğrenmesi Modellerinin Eğitim ve Test Edilmesi 23

3.4.1 Model Karşılaştırma ve Seçimi 23

3.4.2 Random Forest Tercih Edilmesinin Sebebi 23

3.4.3 Hiperparametre Yapılandırması 24

3.4.4 Eğitim ve Test Süreci 24

3.4.5 Girdilerin kullanıcıdan alarak tahmin yapan arayüz tasarımı 27

4.ELDE EDİLEN BULGULAR VE GELECEK ÇALIŞMALAR **28**

KAYNAKÇA **29**

EKLER **31**

Pasta grafikleri 31

Histogramlar 34

Şekillerin Listesi

Şekil **Sayfa**

Şekil 2.1 CRISP-DM Basamakları **2**

Şekil 3.1 Veri Setinin Spyder'daki Görünümü **6**

Şekil 3.2 Veri Setini Yüklemede Kullanılan Kod **7**

Şekil 3.3 Keşifsel Veri Analizi Şeması **8**

Şekil 3.4 Tanımlayıcı İstatistik İçin Kullanılan Kod Bloğu **9**

Şekil 3.5 Tanımlayıcı İstatistik Çıktıları **10**

Şekil 3.6 Hedef Değişkene Ait Pasta Grafiği **11**

Şekil 3.7 Kazaya Karışan Araç Sayısı..... 15

Şekil 3.8 Aykırı Değer Analizi'nin Kutu Grafiği ile Gösterimi..... 16

Şekil 3.9 Korelasyon Matris..... 18

Şekil 3.10 Kategorik Verileri Dönüştürme Kod Bloğu..... 19

Şekil 3.11 Bağımlı ve Bağımsız Değişkenleri Gruplama Kod Bloğu..... 19

Şekil 3.12 Gereksiz Sütunların Atılması..... 20

Şekil 3.13 Kaza Şiddetini Etkileyen En Önemli Faktörler..... 21

Şekil 3.14 Eğitim Kod Bloğu 21

Şekil 3.15 Veri Dengeleme Kod Bloğu..... 22

Şekil 3.16 Model Seçimi..... 23

Şekil 3.17 Modellerin Doğruluk Oranı..... 24

Şekil 3.18 Random Forest Hiperparametre Yapılandırması..... 24

Şekil 3.19 Doğruluk Oranı..... 25

1.GİRİŞ

21.yy. da karayolu ulaşımı önemli bir yere sahiptir.Gelişen teknoloji ve nüfus artışının doğal bir sonucu olarak bireysel araç kullanımı da artış göstermiştir. Bu sebeple, trafik kazalarını, sonuçlarını ve temelde yatan nedenleri araştırmak büyük bir önem arz etmektedir.

1.1 Problemin Tanımı

Günümüzde meydana gelen kazalar hem can hem de mal kaybına sebep olmaktadır. Bunun sonucunda ise birey ve kurumlar hem sosyal hem de ekonomik açıdan olumsuz etkilenmektedir.

Geçmiş verilerden elde edilen kaza kayıtları kullanılarak birtakım istatistiksel ve matematik yöntemlerle neden tahmini çalışmaları yapılmaktadır. Fakat veri miktarının fazlalığından kaynaklı birçoğu yetersiz kalmaktadır.

Bu çalışmada kaza verileri kullanılarak makine öğrenmesi yardımıyla yaralanma seviyesinin tahmin edilmesi hedeflenmektedir.Bu şekilde sık karşılaşılan yaralanma çeşitlerinin tespit edilmesi ve gelecekte ortaya çıkabilecek riskli durumların öngörülmesi hedeflenmektedir.

1.2. Çalışmanın Amacı ve Önemi

Bu çalışmanın temel amacı, kaza veri seti kullanılarak makine öğrenmesi yardımıyla bir kazada ortaya çıkan en ağır yaralanma seviyesinin tahmin edilmesidir ve bir sınıflandırma problemi olarak ele alınmıştır.Bu kapsamda, kaza kayıtlarından elde edilen çok değişkenli bir veriseti analiz edilip kazayı etkileyen temel değişkenler ve aralarındaki ilişkilerin saptanması hedeflenmektedir.

Çalışmanın önemi,kaza kayıtlarının geriye dönük incelenmesini yanı sıra veri odaklı tahmin yöntemleri aracılığıyla geleceğe dönük çıkarım yapılabilmesinden kaynaklanmaktadır.Elde edilen bulgular sonucunda, riskli durumların önceden tespiti ve önleyici tedbirlerin daha etkin planlanması beklenmektedir. Ayrıca makine öğrenmesi yöntemlerinin kaza analizi alanında uygulanabilirliği de gösterilmiş olup akademik literatüre katkı sunulmaktadır.

1.3. Çalışmanın Kapsamı ve Katkıları

Bu çalışma, geçmiş kaza kayıtlarından elde edilen bir veriseti ile sınırlıdır. Çalışma kapsamında ise esas yaralanma seviyesine ilişkin tahmin problemi ele alınmış olup, denetimli öğrenme çerçevesinde bir sınıflandırma problemi olarak incelenmiştir. Veri ön işleme, eksik değerlerin giderilmesi, özellik çıkarma ve seçme, makine öğrenmesi algoritmalarının uygulanması ve

modelleme aşamaları bu çalışmanın kapsamını oluşturmaktadır. Gerçek zamanlı veri kullanımı çalışma kapsamının dışında bırakılmıştır.

Çalışmanın katkıları üç başlık altında değerlendirilebilir. İlk olarak, yaralanma seviyesi tahminine yönelik makine öğrenmesi yöntemleri kullanılarak veri temelli karar destek süreçlerine katkı sağlanmıştır. İkinci olarak. CRISP-DM çerçevesinde bir uygulama gerçekleştirilerek kaza analizi konusunda uygulanabilir bir örnek sunulmuştur. Son olarak, elde edilen bulguların önleyici tedbirlerin alınması sürecinde yol gösterici nitelikte olmaları hedeflenmiştir.

2.CRISP-DM Metodolojisi

CRISP-DM, problemlerin veriye dayalı yaklaşımlarla analiz edilmesini, elde edilen sonuçların değerlendirilerek uygulamaya aktarılmasını amaçlayan ve altı aşamadan oluşan standart bir süreç modelidir. Bu aşamalar; problemin doğru tanımlanması, verinin anlaşılması, verinin hazırlanması, modelleme, değerlendirme ve sonuçların uygulamaya alınması adımlarını kapsamaktadır. (bkz. Şekil 2.1)

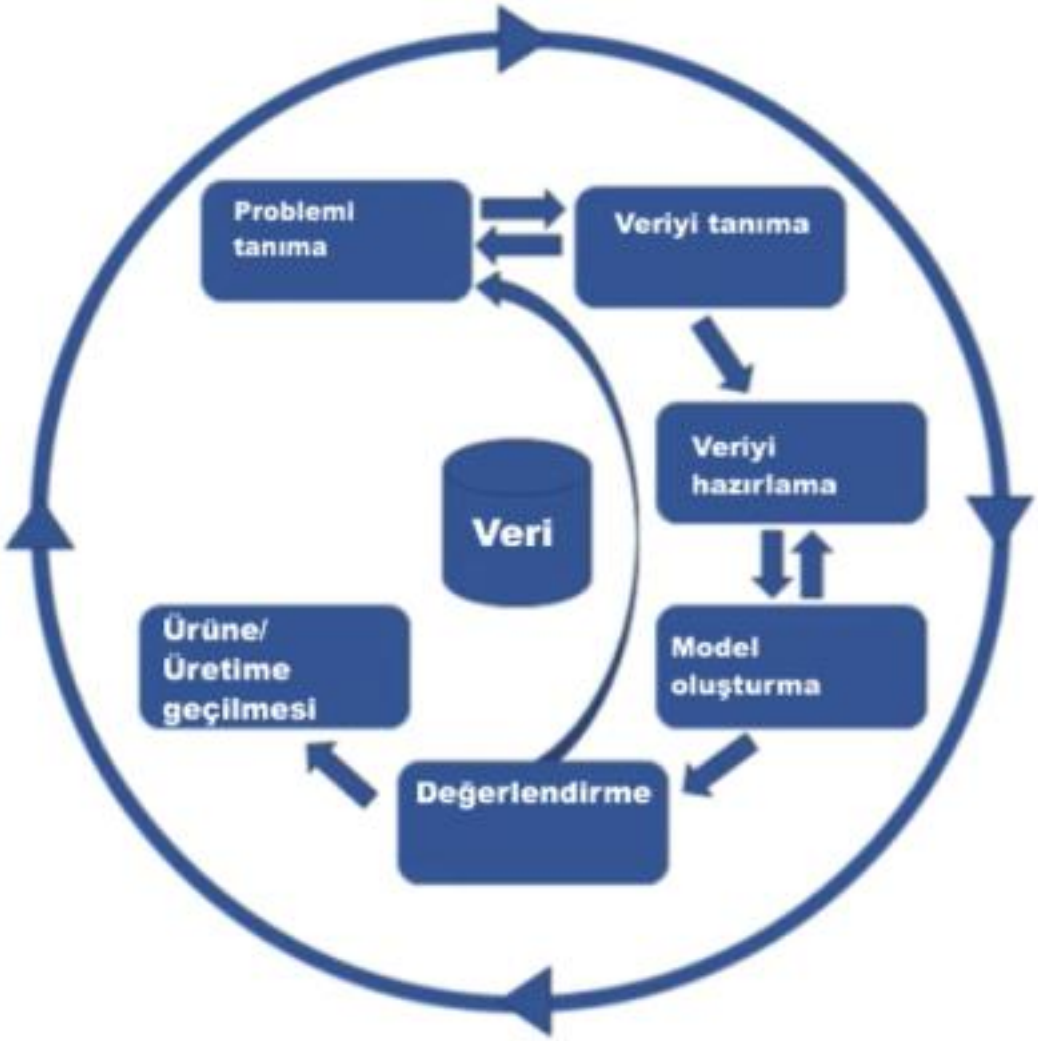

Şekil 2.1 CRIISP-DM Basamakları

2.1. Problemi Anlama

Bu aşamada çalışmanın amacı net bir şekilde belirlenir. Hangi problemin çözüleceği, projeden ne beklendiği ve elde edilmek istenen sonuçlar ortaya konur. Böylece çalışma doğru bir hedef doğrultusunda başlatılmış olur.

2.2. Veriyi Anlama

Kullanılacak veri seti bu aşamada incelenir. Verinin kaynağı, içeriği ve genel yapısı değerlendirilir. Eksik, hatalı veya tutarsız veriler bu aşamada tespit edilmeye çalışılır.

2.3. Veriyi Hazırlama

Veriler analiz ve modelleme için uygun hâle getirilir. Eksik veriler düzeltilir, gereksiz değişkenler veri setinden çıkarılır ve analizde kullanılacak son hâli oluşturulur. Bu aşama genellikle en fazla zaman alan aşamadır.

2.4. Modelleme

Hazırlanan veri seti kullanılarak uygun analiz veya makine öğrenmesi yöntemleri seçilir ve modeller oluşturulur. Farklı modeller denenerek en uygun olanı belirlenmeye çalışılır.

2.5. Değerlendirme

Oluşturulan modelin başarısı bu aşamada değerlendirilir. Elde edilen sonuçların başlangıçta belirlenen probleme uygun olup olmadığı kontrol edilir.

2.6. Uygulamaya Alma

Son aşamada elde edilen sonuçlar rapor hâline getirilir ve gerektiğinde gerçek sistemlerde kullanılmak üzere uygulamaya aktarılır.

3.UYGULAMA

3.1. İş Anlayışı (Business Understanding)

Bu bölümde, ele alınan problemin uygulama bağlamındaki gereksinimleri,hedefler ve kısıtlar ele alınmıştır. Bir kazada en ağır yaralanma çeşidi tahminine yönelik olarak geliştirilecek modelin , karar destek süreçlerine katkı sağlayacak biçimde ele alınması amaçlanmaktadır.

3.1.1. Problemin Tanımlanması

Bu çalışmada, trafik kazalarına ait çeşitli özellikler kullanılarak kazada meydana gelen en ağır yaralanma düzeyinin (most severe injury) makine öğrenmesi yöntemleriyle tahmin edilmesi hedeflenmektedir. Problem, çıktı değişkeninin kategorik yapıda olmasından dolayı bir sınıflandırma problemi olarak ele alınmıştır.

3.1.2. Niteliklerin Belirlenmesi

Bu çalışmada,trafik kazalarının meydana gelme koşullarını ve kaza şiddetini etkileyen ve literatürde sıklıkla vurgulanan çevresel, zamansal ve yapısal faktörlerin olduğu bir veriseti seçilmiştir. Değişkenler ise şu şekildedir:

Kaza Tarihi (crash_date)

Trafik Kontrol Cihazı (traffic_control_device)

Hava Durumu (weather_condition)

Aydınlatma Durumu (lighting_condition)

İlk Çarpışma Türü (first_crash_type)

Yol Türü (trafficway_type)

Yol Hizalaması (alignment)

Yol Yüzey Durumu (roadway_surface_cond)

Yol Kusuru (road_defect)

Kaza Türü (crash_type)

Kavşak İlişkisi (intersection_related_i)

Hasar Durumu (damage)

Birincil Kaza Nedeni (prim_contributory_cause)

Kazaya Karışan Araç Sayısı (num_units)

En Ağır Yaralanma Düzeyi (most_severe_injury)

Toplam Yaralanma Sayısı (injuries_total)

Ölümcül Yaralanma Sayısı (injuries_fatal)

Ağır Yaralanma Sayısı (injuries_incapacitating)

Hafif Yaralanma Sayısı (injuries_non_incapacitating)

Belirti Göstermeyen Bildirilmiş Yaralanmalar (injuries_reported_not_evident)

Yaralanma Olmayan Kişi Sayısı (injuries_no_indication)

Kaza Saati (crash_hour)

Kazanın Gerçekleştiği Gün (crash_day_of_week)

Kazanın Gerçekleştiği Ay (crash_month)

3.1.3. Verilerin Toplanması

Bu çalışmada kullanılan veriler, Kaggle websitesinde trafik kazalarına ait kayıtların yer aldığı bir verisetinden elde edilmiştir. Veri seti; kazaların tarih, çevresel koşullar, yol özellikleri ve yaralanma durumları hakkında bazı bilgileri içermektedir. Analiz sürecinde kullanılan veriler, makine öğrenmesi uygulamalarına uygun olacak şekilde düzenlenmiş ve çalışmaya dahil edilmiştir. Şekil 3.1'de veri setinin Spyder'daki görünümü verilmiştir.

Index	traffic_control_device	weather_condition	lighting_condition	first_crash_type	trafficway_type	alignment	dway_surface_co	road_defect	crash_type	ection_rela	damage	ma
0	TRAFFIC SIGNAL	CLEAR	DAYLIGHT	TURNING	NOT DIVIDED	STRAIGHT AND LEVEL	UNKNOWN	UNKNOWN	NO INJURY / DRIVE AWAY	Y	$501 - $1,500	NO INDI
1	TRAFFIC SIGNAL	CLEAR	DARKNESS, LIGHTED ROAD	TURNING	FOUR WAY	STRAIGHT AND LEVEL	DRY	NO DEFECTS	NO INJURY / DRIVE AWAY	Y	OVER $1,500	NO INDI
2	TRAFFIC SIGNAL	CLEAR	DAYLIGHT	REAR END	T-INTERSECTION	STRAIGHT AND LEVEL	DRY	NO DEFECTS	NO INJURY / DRIVE AWAY	Y	$501 - $1,500	NO INDI
3	TRAFFIC SIGNAL	CLEAR	DAYLIGHT	ANGLE	FOUR WAY	STRAIGHT AND LEVEL	DRY	NO DEFECTS	INJURY AND / OR TOW DUE TO CRASH	Y	OVER $1,500	NONINCA
4	TRAFFIC SIGNAL	CLEAR	DAYLIGHT	REAR END	T-INTERSECTION	STRAIGHT AND LEVEL	UNKNOWN	UNKNOWN	NO INJURY / DRIVE AWAY	Y	$501 - $1,500	NO INDI
5	NO CONTROLS	RAIN	DARKNESS, LIGHTED ROAD	FIXED OBJECT	NOT DIVIDED	STRAIGHT AND LEVEL	WET	UNKNOWN	INJURY AND / OR TOW DUE TO CRASH	N	$501 - $1,500	NONINCA
6	TRAFFIC SIGNAL	CLEAR	DAYLIGHT	REAR TO FRONT	FOUR WAY	STRAIGHT AND LEVEL	DRY	NO DEFECTS	NO INJURY / DRIVE AWAY	Y	$501 - $1,500	NO INDI
7	NO CONTROLS	CLEAR	DAYLIGHT	ANGLE	DIVIDED - W/MEDIAN (NOT RAISED)	CURVE, LEVEL	DRY	NO DEFECTS	INJURY AND / OR TOW DUE TO CRASH	Y	OVER $1,500	NONINCA
8	TRAFFIC SIGNAL	CLEAR	DAYLIGHT	REAR END	NOT DIVIDED	STRAIGHT AND LEVEL	DRY	NO DEFECTS	NO INJURY / DRIVE AWAY	Y	OVER $1,500	NO INDI
9	STOP SIGN/FLASHER	CLEAR	DAYLIGHT	ANGLE	FOUR WAY	STRAIGHT AND LEVEL	DRY	NO DEFECTS	NO INJURY / DRIVE AWAY	Y	OVER $1,500	NO INDI
10	TRAFFIC SIGNAL	CLEAR	DARKNESS, LIGHTED ROAD	FIXED OBJECT	NOT DIVIDED	STRAIGHT AND LEVEL	DRY	UNKNOWN	NO INJURY / DRIVE AWAY	Y	OVER $1,500	NO INDI
11	TRAFFIC SIGNAL	RAIN	DUSK	ANGLE	OTHER	STRAIGHT AND LEVEL	WET	NO DEFECTS	NO INJURY / DRIVE AWAY	Y	OVER $1,500	NO INDI
12	UNKNOWN	CLEAR	DAYLIGHT	TURNING	UNKNOWN INTERSECTION TYPE	STRAIGHT AND LEVEL	DRY	NO DEFECTS	NO INJURY / DRIVE AWAY	Y	OVER $1,500	NO INDI
13	NO CONTROLS	CLEAR	DAYLIGHT	SIDESWIPE SAME DIRECTION	ONE-WAY	STRAIGHT AND LEVEL	DRY	NO DEFECTS	NO INJURY / DRIVE AWAY	Y	OVER $1,500	NO INDI
14	TRAFFIC SIGNAL	SNOW	DAYLIGHT	REAR END	RAMP	STRAIGHT AND LEVEL	SNOW OR SLUSH	NO DEFECTS	NO INJURY / DRIVE AWAY	Y	OVER $1,500	NO INDI
15	NO CONTROLS	CLEAR	DARKNESS, LIGHTED ROAD	SIDESWIPE OPPOSITE DIRECTION	NOT DIVIDED	STRAIGHT AND LEVEL	DRY	NO DEFECTS	INJURY AND / OR TOW DUE TO CRASH	N	OVER $1,500	INCAPAC
16	TRAFFIC SIGNAL	CLEAR	DAYLIGHT	PEDALCYCLIST	TRAFFIC ROUTE	STRAIGHT AND LEVEL	DRY	NO DEFECTS	INJURY AND / OR TOW DUE TO CRASH	N	$500 OR LESS	REPORTE
17	TRAFFIC SIGNAL	CLEAR	DUSK	ANGLE	FIVE POINT, OR MORE	STRAIGHT AND LEVEL	DRY	NO DEFECTS	INJURY AND / OR TOW DUE TO CRASH	Y	OVER $1,500	INCAPAC
18	TRAFFIC SIGNAL	CLEAR	DAYLIGHT	SIDESWIPE SAME DIRECTION	FOUR WAY	STRAIGHT AND LEVEL	DRY	NO DEFECTS	NO INJURY / DRIVE AWAY	Y	OVER $1,500	NO INDI
19	STOP SIGN/FLASHER	CLEAR	DAYLIGHT	TURNING	ONE-WAY	STRAIGHT AND LEVEL	UNKNOWN	UNKNOWN	NO INJURY / DRIVE AWAY	Y	$500 OR LESS	NO INDI
20	NO CONTROLS	CLEAR	DAYLIGHT	REAR END	NOT DIVIDED	STRAIGHT AND LEVEL	DRY	NO DEFECTS	NO INJURY / DRIVE AWAY	Y	OVER $1,500	NO INDI
21	TRAFFIC SIGNAL	CLEAR	DARKNESS, LIGHTED ROAD	TURNING	FOUR WAY	STRAIGHT AND LEVEL	DRY	NO DEFECTS	NO INJURY / DRIVE AWAY	Y	OVER $1,500	NO INDI
22	STOP SIGN/FLASHER	CLEAR	DAYLIGHT	TURNING	T-INTERSECTION	STRAIGHT AND LEVEL	DRY	NO DEFECTS	INJURY AND / OR TOW DUE TO CRASH	Y	OVER $1,500	REPORTE

Şekil 3.1 Veri setinin Spyder'daki Görünümü

Veri setindeki her bir satır bir örneği yani gözlemi temsil etmekte olup, bu gözlemler tekil bir trafik kazasına karşılık gelmektedir. Sütunlar ise öznitelikleri (özellikleri) ifade etmektedir. Bu öznitelikler; kaza zamanı, hava koşulları, yol durumu, trafik kontrol unsurları ve kazaya karışan araç sayısı gibi konuya ilişkin farklı faktörlerden oluşmaktadır.

Bu çalışmada kullanılan özellikler, modelleme sürecinde bağımsız değişkenler (girdi değişkenleri) ve bağımlı değişken (hedef değişken) olmak üzere iki ana grup şekinde ayrılmıştır. Bağımsız değişkenler; kazanın oluşum koşullarını ve çevresel faktörlerini açıklayan değişkenlerden oluşurken, bağımlı değişken kazanın sonucunda ortaya çıkan en ağır yaralanma çeşidini temsil etmektedir.

Bu kapsamda, hava durumu, aydınlatma koşulları, yol tipi, yol yüzeyi durumu, kavşak bilgisi, kaza saati, gün ve ay bilgileri ile kazaya karışan araç sayısı gibi değişkenler bağımsız değişkenler olarak ele alınmıştır. Kazanın yol açtığı en ağır yaralanma durumunu gösteren most_severe_injury değişkeni ise çalışmanın hedef (bağımlı) değişkeni olarak seçilmiştir. Bu değişken, kazaların yaralanma şiddetine göre sınıflandırılmasını sağladığı için sınıflandırma problemlerinde sınıf etiketi olarak kullanılmaktadır. Hedef değişkendeki sınıflar ise no injury(yaralanma yok), reported but not evident(bildirilmiş fakat belirgin yaralanma yok), non-incapacitating injury(hafif yaralanma/işlev kaybına yok açmayan yaralanma),incapacitating injury(ağır yaralanma/işlev kaybına yol açan yaralanma),fatal(ölümcül kaza/ölümle sonuçlanan yaralanma) olmak üzere beş tanedir.

Çalışmada kullanılan veri seti boyutu, gözlem sayısı ve öznitelik sayısı bakımından incelendiğinde, makine öğrenmesi modellerinin eğitimi ve değerlendirilmesi için yeterli çeşitliliğe sahip olduğu görülmüştür. Toplanan veriler, daha sonraki aşamalarda keşifsel veri analizi (EDA), veri ön işleme ve modelleme adımlarında kullanılmak üzere düzenlenmiş ve analiz sürecine hazır hale getirilmiştir.

3.1.4. Veri Setinin Yüklenmesi

Trafik kazalarına ait veri seti öcelikle .csv formatından Excel (.xlsx) formatına çevrilmiştir ve Python programlama dili kullanılarak analiz ortamına aktarılmıştır. Veri setinin yüklenmesi işlemi, pandas kütüphanesi yardımıyla gerçekleştirilmiş ve ilgili çalışma sayfasındaki veriler bir veri çerçevesi (DataFrame) olarak okunmuştur.

```
#Veri Setinin Yüklenmesi
import pandas as pd
veriseti=pd.read_excel('trafik_kazalari_yzp.xlsx', 'veriler')
```

Şekil 3.2 Veri Setini Yüklemede Kullanılan Kod

3.2. Veriyi Anlama (Data Understanding)

Bu aşamada, çalışmada kullanılan trafik kazası veri setinin genel yapısını incelemek amacıyla Keşifsel Veri Analizi'nden (Exploratory Data Analysis – EDA) yararlanılmıştır. EDA kapsamında veri setinin temel istatistiksel özellikleri incelenmiş olup değişkenlerin dağılımları görselleştirilmiş ve değişkenler arasındaki ilişkiler analiz edilmiştir.Bu süreçte tanımlayıcı istatistikler, pasta grafikler ve histogramlar kullanılarak veri setinin dağılım yapısı değerlendirilmiştir. Ayrıca sayısal değişkenler için aykırı değer analizi yapılmış ve korelasyon analizi ile değişkenler arasındaki doğrusal ilişkiler incelenmiştir. Elde edilen bulgular, veri ön işleme ve modelleme aşamalarına temel oluşturmuştur.Şekil 3.3'te Keşifsel Veri Analizi'ni gösteren şema paylaşılmıştır.

Şekil 3.3 Keşifsel Veri Analizi Şeması

3.2.1. Tanımlayıcı İstatistikler

Tanımlayıcı istatistikler için kullanılan kod bloğu Şekil 3.4'te,çalıştırıldığında alınan çıktı ise Şekil 3.5'te gösterilmiştir.

```python
#Tanımlayıcı İstatistikler
veriseti.info()
print(veriseti.describe())
print(veriseti.describe(include=["object"]))

veriseti = veriseti.drop([
    'crash_date',
    'road_defect',
    'crash_type',
    'damage',
    'injuries_total',
    'injuries_fatal',
    'injuries_incapacitating',
    'injuries_non_incapacitating',
    'injuries_reported_not_evident',
    'injuries_no_indication',
    'crash_month'
], axis=1)
```

Şekil 3.4 Tanımlayıcı İstatistik İçin Kullanılan Kod Bloğu

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 209306 entries, 0 to 209305
Data columns (total 24 columns):
 #   Column                         Non-Null Count   Dtype
---  ------                         --------------   -----
 0   crash_date                     209306 non-null  object
 1   traffic_control_device         209306 non-null  object
 2   weather_condition              209306 non-null  object
 3   lighting_condition             209306 non-null  object
 4   first_crash_type               209306 non-null  object
 5   trafficway_type                209306 non-null  object
 6   alignment                      209306 non-null  object
 7   roadway_surface_cond           209306 non-null  object
 8   road_defect                    209306 non-null  object
 9   crash_type                     209306 non-null  object
 10  intersection_related_i         209306 non-null  object
 11  damage                         209306 non-null  object
 12  prim_contributory_cause        209306 non-null  object
 13  num_units                      209306 non-null  int64
 14  most_severe_injury             209306 non-null  object
 15  injuries_total                 209306 non-null  float64
 16  injuries_fatal                 209306 non-null  float64
 17  injuries_incapacitating        209306 non-null  float64
 18  injuries_non_incapacitating    209306 non-null  float64
 19  injuries_reported_not_evident  209306 non-null  float64
 20  injuries_no_indication         209306 non-null  float64
 21  crash_hour                     209306 non-null  int64
 22  crash_day_of_week              209306 non-null  int64
 23  crash_month                    209306 non-null  int64
dtypes: float64(6), int64(4), object(14)
memory usage: 38.3+ MB
           num_units  injuries_total  ...  crash_day_of_week    crash_month
count  209306.000000   209306.000000  ...      209306.000000  209306.000000
mean        2.063300        0.382717  ...           4.144024       6.771822
std         0.396012        0.799720  ...           1.966864       3.427593
min         1.000000        0.000000  ...           1.000000       1.000000
25%         2.000000        0.000000  ...           2.000000       4.000000
50%         2.000000        0.000000  ...           4.000000       7.000000
75%         2.000000        1.000000  ...           6.000000      10.000000
max        11.000000       21.000000  ...           7.000000      12.000000

[8 rows x 10 columns]
                    crash_date  ...       most_severe_injury
count                   209306  ...                   209306
unique                  189087  ...                        5
top     12/29/2020 05:00:00 PM  ...  NO INDICATION OF INJURY
freq                        10  ...                   154789

[4 rows x 14 columns]
```

Şekil 3.5 Tanımlayıcı İstatistik Çıktıları

Kod çıktısı incelendiğinde, toplam 209306 gözlem ve 24 öznitelikten oluştuğu görülmektedir. Değişkenlerin veri tipleri değerlendirildiğinde, 14 değişkenin kategorik (object), 4 değişkenin tam sayı (int64) ve 6 değişkenin ondalıklı sayı (float64) tipinde olduğu belirlenmiştir. Tüm değişkenlerde gözlem sayısının 209306 olması, veri setinde eksik değer olmadığını göstermektedir.

Sayısal değişkenlere ait tanımlayıcı istatistikler incelendiğinde, kazalara karışan araç sayısının (num_units) ortalama olarak yaklaşık 2,06 olduğu, medyan değerinin ise 2 olduğu

görülmektedir. Bu durum, kazaların büyük çoğunluğunun iki araç arasında gerçekleştiğini göstermektedir. Yaralanma sayısına ilişkin değişkenlerde (injuries_total, injuries_fatal vb.) ortalama ve medyan değerlerin düşük olması, veri setinde ağır yaralanma ve ölümle sonuçlanan kazaların olmayanlardan daha az olduğunu görülmektedir.

Zamansal değişkenler incelendiğinde, kazaların günün farklı saatlerine dağıldığı (crash_hour değişkeni ortalama 14 çıkmıştır) ve haftanın farklı günlerinde meydana geldiği (crash_day_of_week medyan = 4) gözlemlenmiştir. Ayrıca crash_month değişkeninin çıktıları, kazaların yılın tüm aylarına yayıldığını göstermektedir.

Ayrıca crash_date değişkeninde 189087 farklı tarih-saat değeri bulunduğu için kazaların çok geniş bir zaman aralığına yayıldığı ve hatta bazı zaman dilimlerinde birden fazla kazanın da kaydedildiği(unique<count ve freq=10 olduğu için) görülmektedir.

3.2.2. Pasta Grafiği Oluşturulması

Hedef çıktı olan most_severe_injury için pasta grafiği Şekil 3.6'da verilmiştir.Diğer pasta grafikleri ise Ekler bölümüne eklenmiştir.

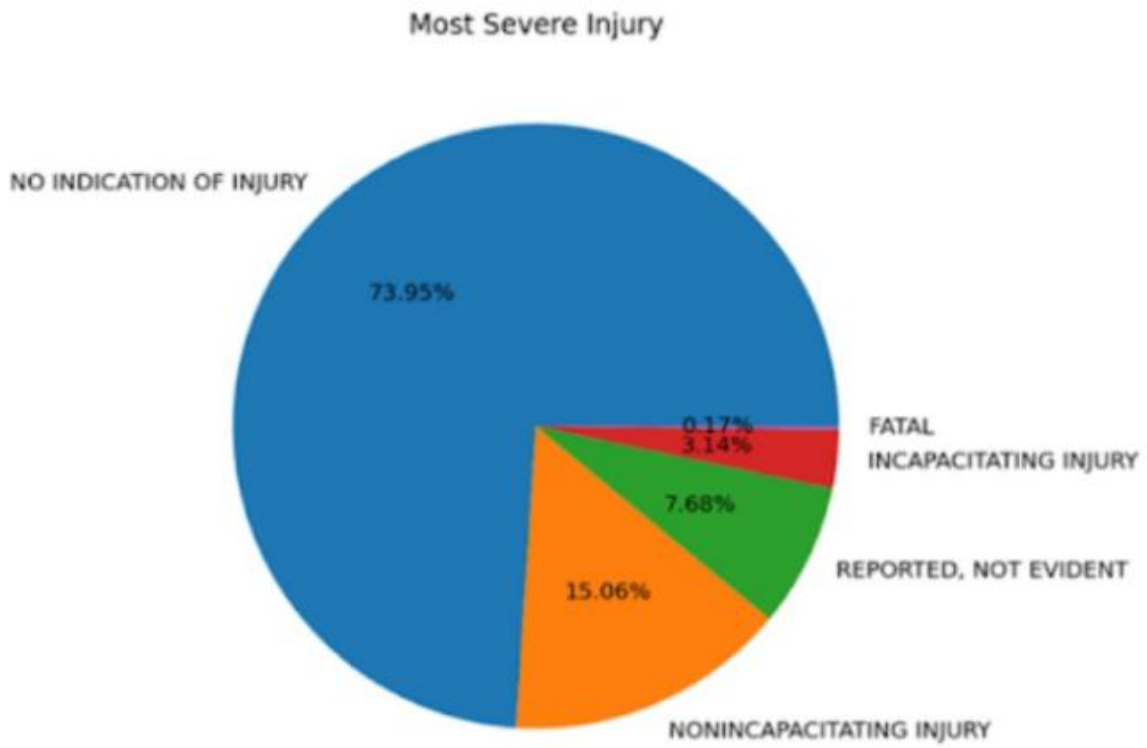

Şekil 3.6 Hedef Değişkene Ait Pasta Grafiği

Kullanılan kod bloğu şu şekildedir:

```
#Pasta grafiği

# Pasta grafiklerini çizmek istediğimiz sütunlar

import matplotlib.pyplot as plt

pie_columns = [

    'traffic_control_device',

    'weather_condition',

    'lighting_condition',

    'first_crash_type',

    'roadway_surface_cond',

    'damage',

    'prim_contributory_cause',

    'most_severe_injury'

]

# Konsolide etme eşiği (Yüzde cinsinden). %1'in altındaki dilimler birleştirilir.

THRESHOLD_PERCENT = 1.0

# Yüzde gösterimini kontrol eden özel fonksiyon (Sadece eşiği geçenlerde gösterir)

def autopct_format(pct):

    return ('%1.1f%%' % pct) if pct >= THRESHOLD_PERCENT else ''

for col in pie_columns:

    print(f"\n--- Sütun: {col} ---")

    # 1. Kategori sayımlarını al

    counts = veriseti[col].value_counts()
```

```
print("Orijinal Kategori Sayımları:")
print(counts)
# Kategori Birleştirme Mantığı
total = counts.sum()
threshold_count = total * (THRESHOLD_PERCENT / 100)
# Eşiğin altındaki ve üstündeki kategorileri ayır
small_categories = counts[counts < threshold_count]
large_categories = counts[counts >= threshold_count]
# Küçük kategorileri topla ve 'Diğer' olarak adlandır
if not small_categories.empty:
    other_count = small_categories.sum()
    # Yeni sayımları oluştur
    cleaned_counts = pd.concat([large_categories, pd.Series(other_count, index=['Diğer'])])
else:
    cleaned_counts = large_categories
print(f"\nTemizlenmiş Kategori Sayımları (Eşik: %{THRESHOLD_PERCENT}):")
print(cleaned_counts)
# 2. Pasta Grafiğini Çiz
plt.figure(figsize=(12, 12))
# Pasta grafiğini oluştur, temizlenmiş sayımları kullan
cleaned_counts.plot(
    kind='pie',
    autopct=autopct_format, # Etiketleri temizleyen formatı kullan
    startangle=90,
```

```
    wedgeprops={'edgecolor': 'black'},
    pctdistance=0.8 # Yüzdeleri merkeze biraz daha yaklaştırarak çakışmayı azalt
)
# Başlığı ayarla
plt.title(f'{col} Dağılımı (Temizlenmiş Pasta Grafiği)', fontsize=14)
# Y ekseni etiketini kaldır
plt.ylabel('')
# Grafiği kaydet (Hata düzeltildi: plt.savefig kullanıldı)
safe_col_name = col.replace(' ', '_').replace('/', '_')
file_name = f'pasta_grafiği_{safe_col_name}_temiz.png'
plt.savefig(file_name)
```

Bu kod ile birlikte kategorik değişkenlerdeki çok düşük yüzdelik dilime sahip olan sınıflar birleştirilmiş olup bu şekilde daha anlaşılır görünümde pasta grafikleri elde edilmiştir.

3.2.3. Histogramların Oluşturulması

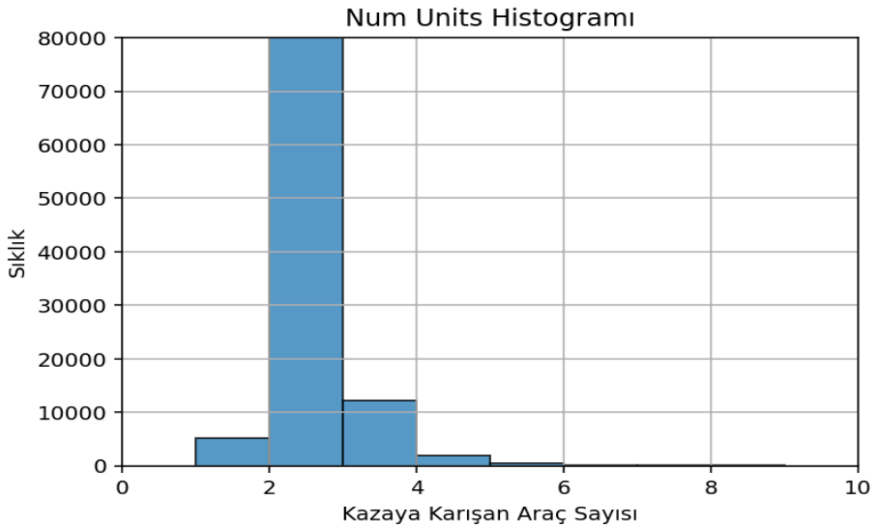

Şekil 3.7 Kazaya Karışan Araç Sayısı

```
# histogramlar

plt.figure()

plt.title("Num Units Histogramı")

plt.xlabel("Kazaya Karışan Araç Sayısı")

plt.ylabel("Sıklık")

plt.axis([0, 10, 0, 80000])

plt.grid(True)

plt.hist(veriseti["num_units"], bins=10, alpha=0.75, edgecolor='black')

plt.show()


plt.figure()

plt.title("Crash Hour Histogramı")

plt.xlabel("Kaza Saati")

plt.ylabel("Sıklık")

plt.axis([0, 24, 0, 50000])
```

```
plt.grid(True)

plt.hist(veriseti["crash_hour"], bins=24, alpha=0.75, edgecolor='black')

plt.show()


plt.figure()

plt.title("Crash Day of Week Histogramı")

plt.xlabel("Haftanın Günü (1=Pzt ... 7=Paz)")

plt.ylabel("Sıklık")

plt.axis([1, 7, 0, 60000])

plt.grid(True)

plt.hist(veriseti["crash_day_of_week"], bins=7, alpha=0.75, edgecolor='black')

plt.show()
```

Histogramların oluşturulmasında kullanılan kod bloğu yukarıda verilmiştir.Oluşturulan diğer histogramlar Ekler kısmında verilmiştir.

3.2.4 Aykırı Değer Analizi

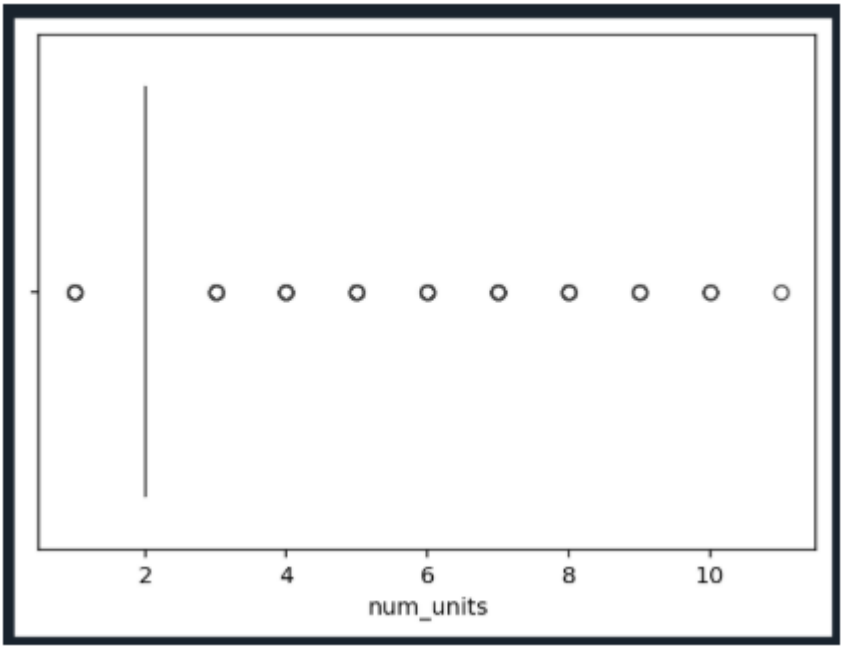

Şekil 3.8 Aykırı Değer Analizi'nin Kutu Grafiği ile Gösterimi

Aykırı değer analizi yapıldığında kazaya karışan birim araç sayısında çok fazla aykırı değer olduğu görülmüştür fakat bu değerler gerçek hayat uygundur, suni değildir.

3.2.5 Korelasyon Analizi

Şekil 3.9'da sunulan korelasyon matrisi incelendiğinde, öznitelikler ve hedef değişken sınıfları arasındaki doğrusal ilişkiler nicel olarak görülmektedir.

Düşük Doğrusal Korelasyon ve Model Seçimi: Bağımsız değişkenlerin (crash_hour, num_units vb.) yaralanma tipleriyle olan doğrusal korelasyon katsayılarının 0.10 seviyesinin altında olması, değişkenler arasındaki ilişkinin doğrusal (linear) olmadığını kesin olarak kanıtlamaktadır. Bu durum, basit regresyon modellerinin bu veri setinde başarısız olacağını, veriler arasındaki karmaşık ve ağaç tabanlı hiyerarşiyi yakalayabilen Random Forest algoritmasının kullanılmasının teknik bir zorunluluk olduğunu doğrulamaktadır.

Öznitelik Bağımsızlığı: num_units, crash_hour ve crash_day_of_week değişkenlerinin kendi aralarındaki korelasyonun sıfıra yakın olması, bu değişkenlerin birbirini tekrar etmediğini (multicollinearity sorunu olmadığını) gösterir. Bu, modelin her bir öznitelikten farklı bir bilgi öğrenmesini sağlamıştır.Girdiler arası korelasyonun düşük olması aranan bir durumdur ve veri seti bunu sağlar.

Sınıf Etkileşimleri: Matriste görülen yüksek negatif değerler (örneğin; Injury_NO INDICATION ile Injury_NONINCAPACITATING arasındaki -0.71), yaralanma sınıflarının birbirini dışlayan (mutually exclusive) yapıda olmasından kaynaklanmaktadır.

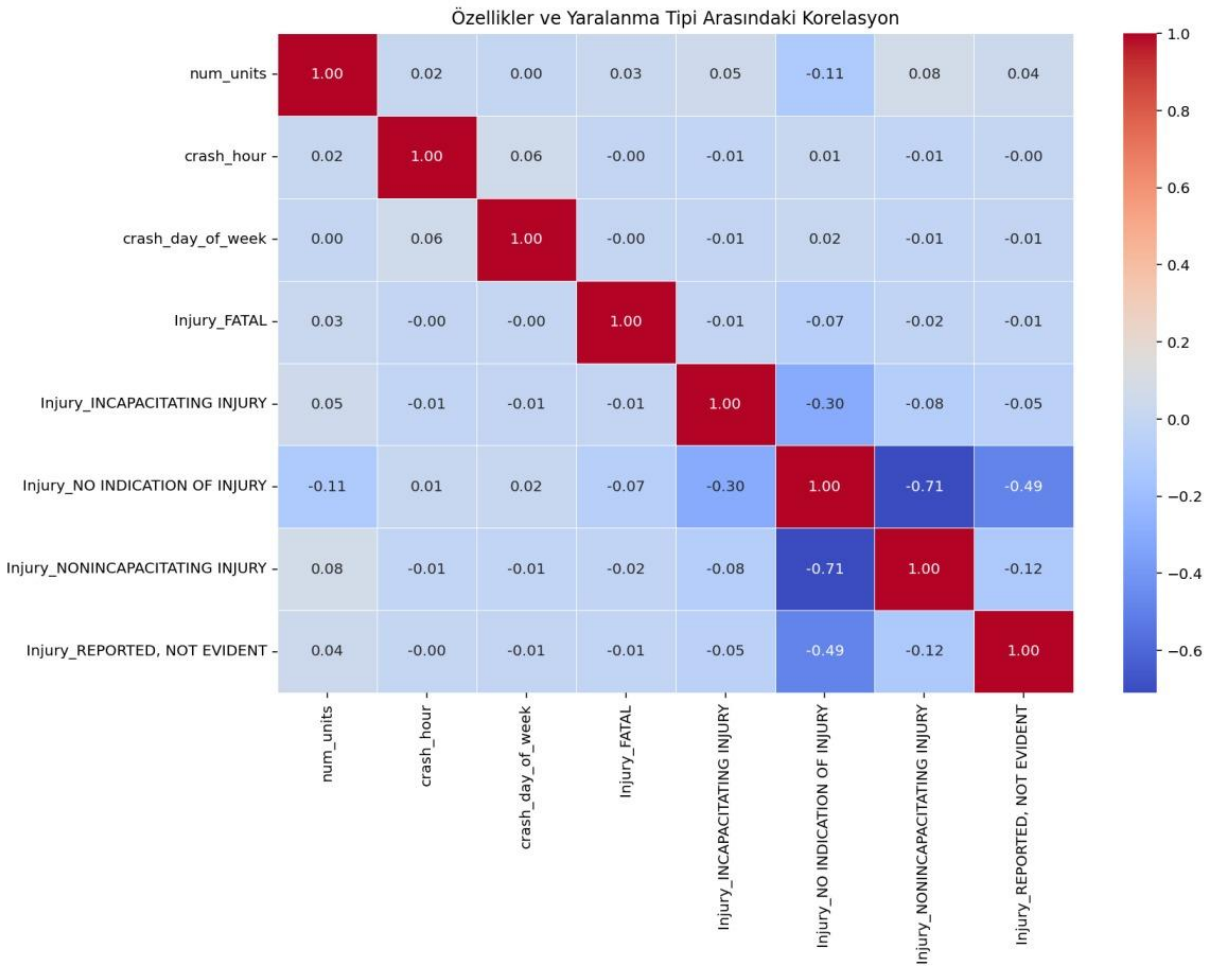

Şekil 3.9 Korelasyon Matrisi

3.3 Veriyi Hazırlama

Bu bölümde, ham veri setinin makine öğrenmesi algoritmaları tarafından işlenebilir hale getirilmesi için uygulanan ön işleme adımları ele alınmıştır.

3.3.1 Kategorik Verilerin Dönüştürülmesi

Makine öğrenmesi algoritmaları sayısal verilerle çalıştığı için, veri setindeki kategorik string biçimindeki değişkenlerin sayısal formatlara dönüştürülmesi gerekmektedir. Bu amaçla, bu çalışmada bağımsız değişkenler için One-Hot Encoding, hedef değişken için ise Label Encoding yöntemi uygulanmıştır.Şekil 3.X’te bu işlem için uygulanan kod verilmiştir.

```
# 3. KATEGORİK VERİLERİ DÖNÜŞTÜRME

# 1. BAĞIMSIZ DEĞİŞKENLERİ (X) ONE-HOT YAPIYORUZ
X = pd.get_dummies(X, columns=X.select_dtypes(include=['object']).columns, drop_first=False)

# 2. HEDEF DEĞİŞKENİ (y) LABEL ENCODER OLARAK BIRAKIYORUZ
le = LabelEncoder()
y = le.fit_transform(y)
```

Şekil 3.10 Kategorik Verileri Dönüştürme Kod Bloğu

One-Hot Encoding:
Bağımsız değişkenlerdeki kategorik sütunlar (örneğin, hava durumu, yol tipi gibi) pd.get_dummies() fonksiyonu ile dönüştürülerek her kategori için ayrı sütunlar oluşturulmuş ve bu kategoriler 0-1 değerleriyle temsil edilmiştir. Böylece modellerin bu kategorileri daha sağlıklı öğrenmesi sağlanmıştır.

Label Encoding:
Hedef değişken olan most_severe_injury, sınıflandırma algoritmaları için LabelEncoder ile sayısal değerlere dönüştürülmüştür. Bu yöntemde, her bir kategori (örneğin "FATAL", "NO INJURY") bir tamsayı ile eşleştirilmiştir.Bu yöntem sıralama bazlı olarak değil,yalnızca sınıflandırma amaçlı kullanılmıştır.

3.3.2 Bağımlı ve Bağımsız Verilerin Gruplara Ayrılması

```
# Hedef ve Öznitelik ayırımı
X = veriseti.drop("most_severe_injury", axis=1)
y = veriseti["most_severe_injury"]
```

Şekil 3.11 Bağımlı ve Bağımsız Değişkenleri Gruplama Kod Bloğu

Modelin eğitilebilmesi için veri seti hedef değişken ve öznitelikler olmak üzere iki ana parçaya ayrılmıştır:

Bağımsız Değişkenler (X): Kaza şiddetini etkileyen dış faktörlerdir (saat, gün, yol yüzeyi, ışık durumu vb.),bağımlı Değişken (y): Tahmin edilmek istenen hedef değişken olan most_severe_injury (Örnek : FATAL,NO INDICATION OF INJURY vb.) sütunudur.

3.3.3 Öznitelik Ölçeklendirme

Projede temel algoritma olarak seçilen “Random Forest” algoritması karar ağaçları topluluğuna dayalı bir modeldir. Farklı karar ağaçlarının oyunu alarak nihai sonuca ulaşmaya çalışır. Karar ağaçları, verileri matematiksel büyüklüklerine göre değil, özellikler üzerindeki "eşik değerlerine" göre böldüğü için mesafe tabanlı algoritmaların (KNN, SVM vb.) aksine verilerin ölçeklendirilmesine ihtiyaç duymaz.

Bu nedenle, veri setindeki crash_hour (0-23) veya num_units gibi farklı aralıklara sahip öznitelikler üzerinde herhangi bir normalizasyon veya standartlaştırma işlemi uygulanmamıştır. Ölçeklendirme işleminin yapılmaması; hem modelin eğitim sürecindeki işlem yükünü azaltmış hem de özniteliklerin orijinal birimlerinde (örneğin saatin 14:00 olması gibi) kalarak sonuçların daha kolay yorumlanabilmesini sağlamıştır. Bu yaklaşım, modelin tahmin başarısında bir kayba yol açmadan kodun daha sade ve verimli tutulmasına olanak tanımıştır.

3.3.4 Özellik Çıkarımı ve Seçimi

Veri setindeki her öznitelik, kaza şiddetini tahmin etmek için aynı bilgi değerine sahip değildir. Modelin karmaşıklığını optimize etmek ve Overfitting (aşırı öğrenme) riskini minimuma indirmek için şu teknikler uygulanmıştır:

Gereksiz Sütunların Atılması: Tahmin başarısını doğrudan etkilemeyen veya hedef değişkenle (kaza şiddeti) çok yüksek korelasyona sahip olduğu için Data Leakage (veri sızıntısı) riski taşıyan toplam 11 sütun çıkarılmıştır. Bu sütunlar; crash_date, road_defect, crash_type, damage, injuries_total, injuries_fatal, injuries_incapacitating, injuries_non_incapacitating, injuries_reported_not_evident, injuries_no_indication ve crash_month olarak belirlenmiştir.

```
# Gereksiz sütunları at
cols_to_drop = ['crash_date', 'road_defect', 'crash_type', 'damage', 'injuries_total',
                'injuries_fatal', 'injuries_incapacitating', 'injuries_non_incapacitating',
                'injuries_reported_not_evident', 'injuries_no_indication', 'crash_month']
veriseti = veriseti.drop(columns=cols_to_drop,axis=1)
```

3.12 Gereksiz Sütunların Atılması

Önem Analizi: Eğitim sonrası Random Forest algoritmasının feature_importances_ özelliği kullanılarak özniteliklerin ağırlıkları hesaplanmıştır. Yapılan analizde crash_hour (kaza saati) ve crash_day_of_week (haftanın günü) gibi zaman tabanlı değişkenlerin kaza şiddeti üzerinde

belirleyici bir role sahip olduğu sayısal olarak kanıtlanmış ve model bu özniteliklerin sunduğu bilgi kazancına (information gain) odaklandırılmıştır.

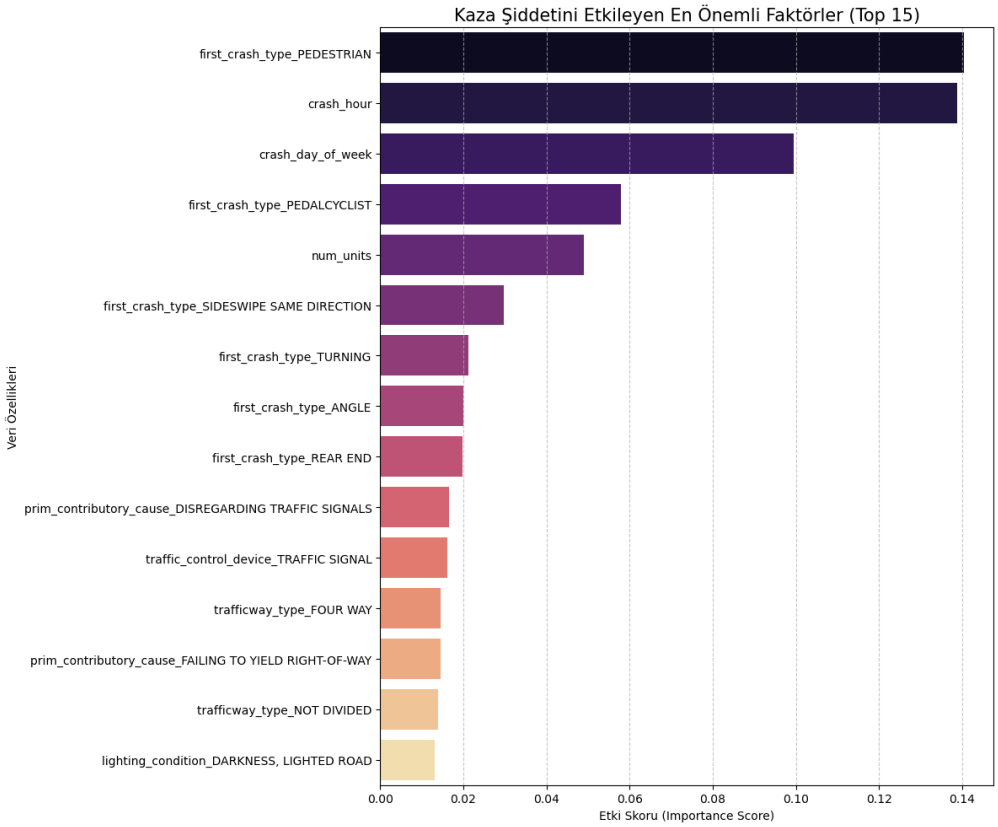

3.13 Kaza Şiddetini Etkileyen En Önemli Faktörler

3.3.5 Eğitim ve Test Veri Setlerinin Oluşturulması

Modelin genelleme yeteneğini ve daha önce karşılaşmadığı veriler üzerindeki performansını objektif bir şekilde ölçebilmek amacıyla veri seti şu aşamalardan geçirilmiştir:

Bölme Oranı: Hazırlanan veri seti, veri bilimi literatüründe standart kabul edilen %80 eğitim ve %20 test seti oranında bölünmüştür. Eğitim seti modelin öğrenme sürecinde, test seti ise modelin başarısının doğrulanmasında kullanılmıştır.

```
# 5. EĞİTİM
X_train, X_test, y_train, y_test = train_test_split(X_resampled, y_resampled, test_size=0.2, random_state=42)
```

3.14 Eğitim Kod Bloğu

Veri Dengeleme (Upsampling): Veri setindeki sınıflar arasında ciddi bir dağılım bozukluğu (imbalance) saptanmıştır. Modelin azınlık sınıfları göz ardı etmemesi için

sklearn.utils.resample yöntemi kullanılmıştır. Ancak, tüm azınlık sınıfların (1, 3, 4) aynı anda ve aynı oranlarda artırılmasının modelde aşırı öğrenmeye (overfitting)yol açtığı gözlemlenmiştir. Bu durum, modelin veriyi öğrenmek yerine kopyalanan satırları ezberlemesine ve gerçek dünya testlerinde "doğruluğu yüksek ama tahmini hatalı" sonuçlar üretmesine neden olmaktadır. Bu nedenle, modelin genelleme kabiliyetini korumak ve en kritik kaza türü olan "Sınıf 0" (Ölümlü) verilerini doğru ayırt edebilmesini sağlamak amacıyla sadece bu sınıfa yönelik seçici bir artırım uygulanarak 3000 örneklem seviyesine çıkarılmıştır. Tüm azınlık sınıfların aynı anda artırılması, modelin veriyi ezberlemesine ve karar sınırlarının bozulmasına yol açmıştır. Modelin genelleme yeteneğini korumak ve en kritik vakaları (Ölümlü) doğru ayırt edebilmesini sağlamak amacıyla, sadece en az veriye sahip olan 'Sınıf 0' üzerinde stratejik bir dengeleme yapılmıştır.

```
# 4. MANUEL VERİ DENGELEME (SINIF 0'I ARTIRMA)

df_egitim = pd.concat([X, pd.Series(y, name='target')], axis=1)

# Sınıfları ayır
df_majority = df_egitim[df_egitim.target == 2] # En çok olan (30k+)
df_minority_0 = df_egitim[df_egitim.target == 0] # Sınıf 0 (56 tane olan)

# Sınıf 0'ı 3000 örneğe kadar kopyalayarak artır
df_minority_0_upsampled = resample(df_minority_0,
                                   replace=True,
                                   n_samples=3000,
                                   random_state=42)

# Diğer sınıfları da dahil ederek yeni veri setini birleştir
df_final = pd.concat([df_majority, df_minority_0_upsampled] +
                     [df_egitim[df_egitim.target == i] for i in [1, 3, 4]])

X_resampled = df_final.drop('target', axis=1)
y_resampled = df_final['target']
```

3.15 Veri Dengeleme

Random State (42): Algoritmanın eğitim ve veri bölme süreçlerinde kullanılan rastgelelik faktörünü sabitlemek amacıyla random_state=42 parametresi kullanılmıştır. Bu, deneyin her çalıştırıldığında aynı sonuçları üretmesini sağlayarak farklı modeller arasındaki karşılaştırmanın tutarlı ve bilimsel olmasını garanti altına almaktadır.

3.4 Makine Öğrenmesi Modellerinin Eğitim ve Test Edilmesi

Bu bölümde, trafik kazası şiddetini tahmin etmek amacıyla kullanılan farklı makine öğrenmesi algoritmaları, bu modellerin birbirleriyle olan performans karşılaştırmaları ve nihai modelin teknik yapılandırması ele alınmıştır.

3.4.1 Model Karşılaştırma ve Seçimi

Proje kapsamında en yüksek başarı oranına ulaşmak için üç farklı mimari karışılaştırılmıştır:

Karar Ağacı (Decision Tree): Veriyi belirli kurallara göre dallara ayıran temel sınıflandırma modelidir. Tekil bir yapı olduğu için veri setindeki gürültüye (noise) karşı hassastır.

Yapay Sinir Ağları (YSA - MLP): İnsan beynindeki nöron yapısını taklit eden, çok katmanlı bir algılayıcı (Multi-Layer Perceptron) modelidir. Doğrusal olmayan karmaşık ilişkileri çözmekte başarılıdır ancak bu veri setinde yüksek işlem gücü gerektirmiştir.

Random Forest Classifier: Projenin ana modeli olarak seçilmiştir. Birden fazla karar ağacının sonuçlarını birleştiren bir topluluk öğrenme (ensemble learning) modelidir.

```
modeller = {
    "Karar Ağacı": DecisionTreeClassifier(random_state=42),
    "Random Forest": RandomForestClassifier(n_estimators=150, max_depth=25, n_jobs=-1, random_state=42),
    "Yapay Sinir Ağları": MLPClassifier(hidden_layer_sizes=(100, 50), max_iter=500, random_state=42)
}
```

3.16 Model Seçimi

3.4.2 Random Forest Tercih Edilmesinin Sebebi

Yapılan testler sonucunda Random Forest modelinin diğer algoritmalara göre daha üstün performans sergilediği görülmüştür. Bu tercihin teknik nedenleri şunlardır:

Topluluk Öğrenme (Ensemble Learning): Birçok karar ağacının "çoğunluk oylaması" yöntemini kullanması sayesinde tekil ağaçların yapabileceği hatalar minimize edilir.

Varyans ve Overfitting Kontrolü: Rastgele örnekleme (bagging) yöntemiyle her ağaç farklı bir veri alt kümesiyle eğitilir. Bunun sonucunda da modelin eğitim verisini ezberlemesini (overfitting) engeller ve genelleme yeteneğini artar.

Tabüler Veri Uyumu: Trafik kazası gibi yapılandırılmış (tabular) verilerde Random Forest, YSA'ya göre daha kararlı ve yüksek doğruluklu sonuçlar üretmektedir.

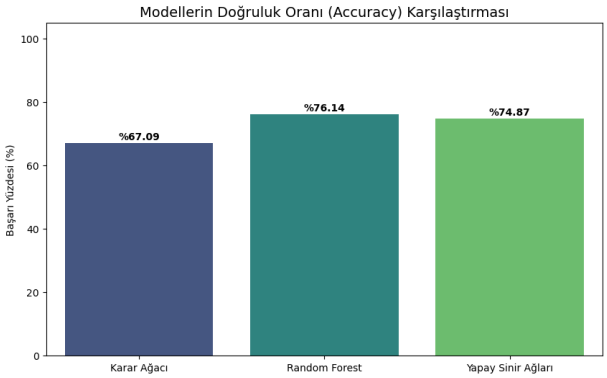

3.17 Modellerin Doğruluk Oranı

3.4.3 Hiperparametre Yapılandırması

Modelin performansı, aşağıdaki hiperparametreler ile optimize edilmiştir:

n_estimators (150): Model bünyesinde oluşturulan toplam karar ağacı sayısıdır. Daha fazla ağaç, daha kararlı tahminler sağlar.

max_depth (25): Ağaçların derinliği 25 katman ile sınırlandırılarak aşırı detaylara inip ezber yapması önlenmiştir.

random_state (42): Algoritmanın her çalıştırıldığında aynı sonuçları üretmesini sağlayarak deneyin tekrarlanabilirliğini garanti altına alır. Rastgeleliği sabitleyerek farklı modeller arasındaki kıyaslamanın daha sağlıklı yapılmasına olanak tanır.

```
model = RandomForestClassifier(n_estimators=150, max_depth=25, random_state=42)
```

3.18 Random Forest Hiperparametre Yapılandırması

3.4.4 Eğitim ve Test Süreci

Veri seti %80 eğitim ve %20 test seti olarak ayrıldıktan sonra süreç şu şekilde işletilmiştir:

1. Eğitim: Hazırlanan dengeli eğitim seti (X_train, y_train) model.fit() fonksiyonu ile algoritmaya verilmiştir.

2. Test: Modelin daha önce görmediği X_test seti üzerinden model.predict() fonksiyonu ile tahminler yürütülmüştür.
3. Ölçüm: Tahmin edilen değerler gerçek y_test değerleri ile kıyaslanarak doğruluk (accuracy) oranı ve hata matrisi (confusion matrix) oluşturulmuştur.

```python
# 5. EĞİTİM
X_train, X_test, y_train, y_test = train_test_split(X_resampled, y_resampled, test_size=0.2, random_state=42)
```

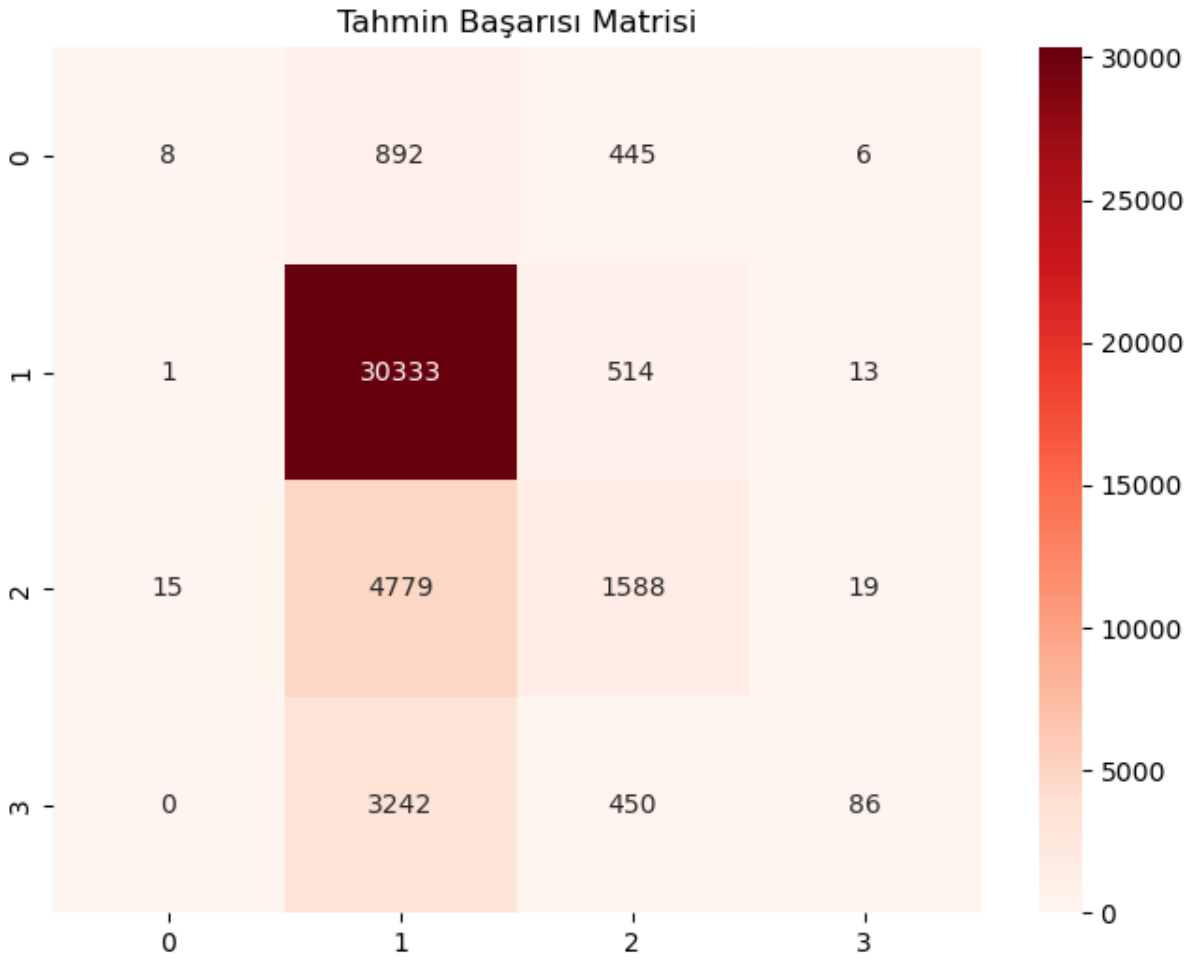


```
==============================
EN İYİ MODEL (RANDOM FOREST) DETAYLI RAPORU
==============================
              precision    recall  f1-score   support

           0       0.95      0.62      0.75       583
           1       0.34      0.01      0.01      1351
           2       0.78      0.98      0.87     30861
           3       0.53      0.25      0.34      6401
           4       0.03      0.00      0.00      3195

    accuracy                           0.76     42391
   macro avg       0.52      0.37      0.39     42391
weighted avg       0.67      0.76      0.69     42391
```

3.19 Doğruluk Oranı

3.4.5 Girdilerin kullanıcıdan alarak tahmin yapan arayüz tasarımı

```python
def kaza_tahmini_yap():
    print("\n" + "="*40)
    print("   YENİ KAZA TAHMİN SİSTEMİ")
    print("="*40)
    print("Girilecek inputlar her bir girdi için şunlardan biri olmalı ve büyük harfle yazılmalı: ")
    print("""
```

```python
    user_input = {}

    for col in girdi_sutunlari:
        deger = input(f"{col}: ")

        # Sayısal veri kontrolü: Verisetindeki sütun tipine bakıyoruz
        dtype = veriseti[col].dtype
        if np.issubdtype(dtype, np.number):
            try:
                user_input[col] = float(deger)
            except ValueError:
                print(f"UYARI: Sayısal değer bekleniyordu. 0.0 atandı.")
                user_input[col] = 0.0
        else:
            # Metin verileri için büyük harfe çevir (Model eğitimiyle uyum için)
            user_input[col] = deger.upper()

    # 3. Veriyi DataFrame'e çeviriyoruz
    df_user = pd.DataFrame([user_input])
    # 4. Model formatına uygun hale getirme (En Kritik Adım)
    # Kullanıcının girdiği veriyi dummy değişkenlere çevirir
    df_user = pd.get_dummies(df_user)
    # Eğitim setindeki (X) sütun yapısını buraya zorluyoruz.
    # Eksik sütunları 0 ile doldurur, fazla varsa atar.
    df_user = df_user.reindex(columns=X.columns, fill_value=0)
    # 5. Tahmin
    tahmin_indeks = model.predict(df_user)
    tahmin_sonuc = le_tahmin.inverse_transform(tahmin_indeks)
    print("\n" + "-"*30)
    print(f"TAHMİN EDİLEN KAZA SONUCU: {tahmin_sonuc[0]}")
    print("-"*30)
# Fonksiyonu çalıştır
kaza_tahmini_yap()
```

Modelin işlevselliğine katkı sunmak amacıyla kullanıcıdan gerekli girdileri alarak modelin amacına uygun şekilde bu girdi şartları altında gerçekleşecek olan kazada ortaya çıkabilecek en ağır sakatlığı tahmin eden bir arayüz, ilgili kodun sonuna eklenmiştir.

4.ELDE EDİLEN BULGULAR VE GELECEK ÇALIŞMALAR

Proje Bulguları:

Model Başarısı: Random Forest algoritması, veri setindeki sınıflar arası ciddi dengesizliğe rağmen en kritik vakalar olan ölümlü kazaları (Sınıf 0) ayırt edebilecek yetkinliğe ulaşmıştır.

Kritik Öznitelikler: Kaza saati ve haftanın günü gibi zamansal değişkenlerin kaza şiddeti üzerinde belirleyici bir role sahip olduğu sayısal olarak kanıtlanmıştır.

Metodolojik Verimlilik: CRISP-DM çerçevesinde yürütülen süreç, ham veriden anlamlı ve uygulanabilir bir karar destek modeli üretilmesini sağlamıştır.

Gelecek Çalışmalar:

Veri Zenginleştirme: Modele gerçek zamanlı hava durumu verileri ve yol bakım kayıtları entegre edilerek tahmin gücü artırılabilir.

Model Karşılaştırması: Mevcut Random Forest başarısı, "Deep Learning" (Derin Öğrenme) mimarileri ve farklı sinir ağı yapılarıyla kıyaslanarak daha derin analizler yapılabilir.

Karşılaştırması: Mevcut Random Forest başarısı, "Deep Learning" (Derin Öğrenme)mimarileri ve farklı sinir ağı yapılarıyla kıyaslanarak daha derin analizler yapılabilir.

KAYNAKÇA

Traffic Accidents [Data set]. (n.d.). Kaggle.

Retrieved December 24, 2025, from https://www.kaggle.com/datasets/oktayrdeki/traffic-accidents

EKLER

Pasta grafikleri

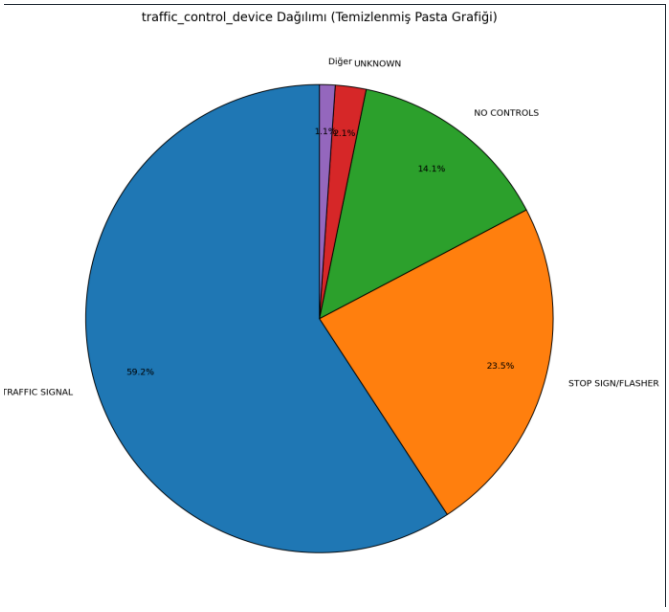

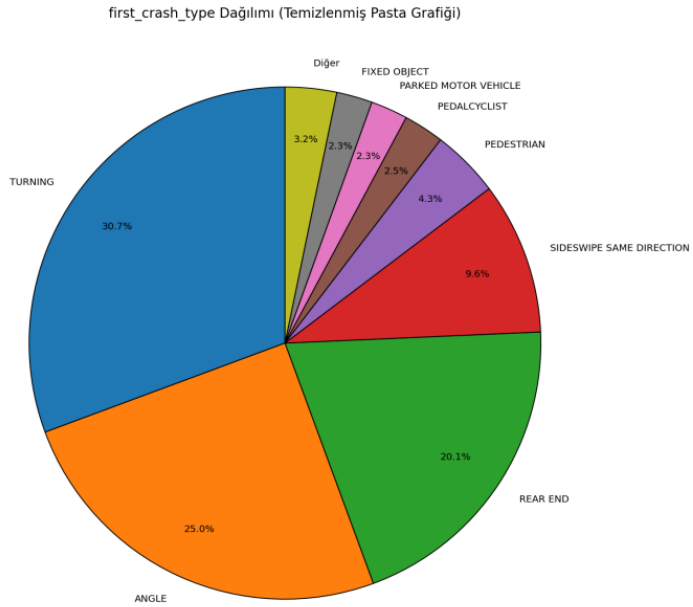

weather_condition Dağılımı (Temizlenmiş Pasta Grafiği)

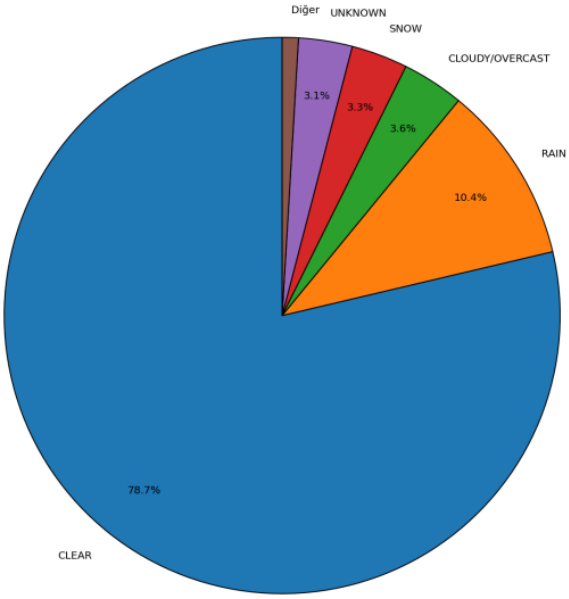

lighting_condition Dağılımı (Temizlenmiş Pasta Grafiği)

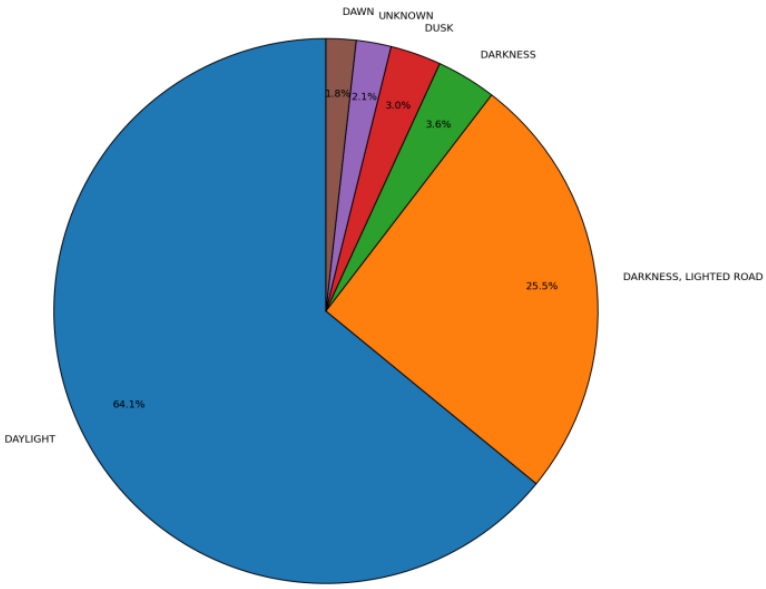

roadway_surface_cond Dağılımı (Temizlenmiş Pasta Grafiği)

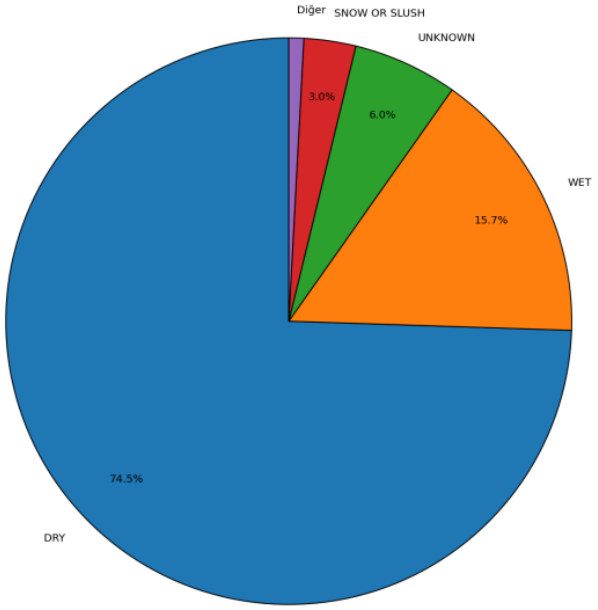

prim_contributory_cause Dağılımı (Temizlenmiş Pasta Grafiği)

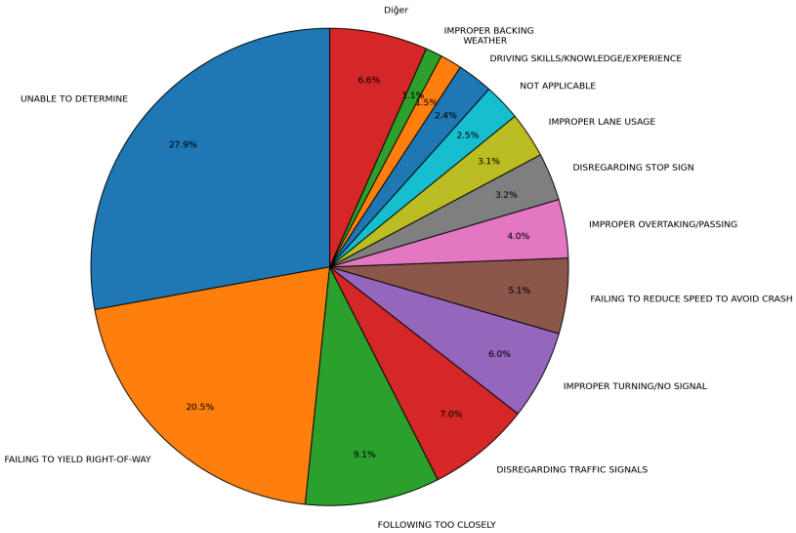
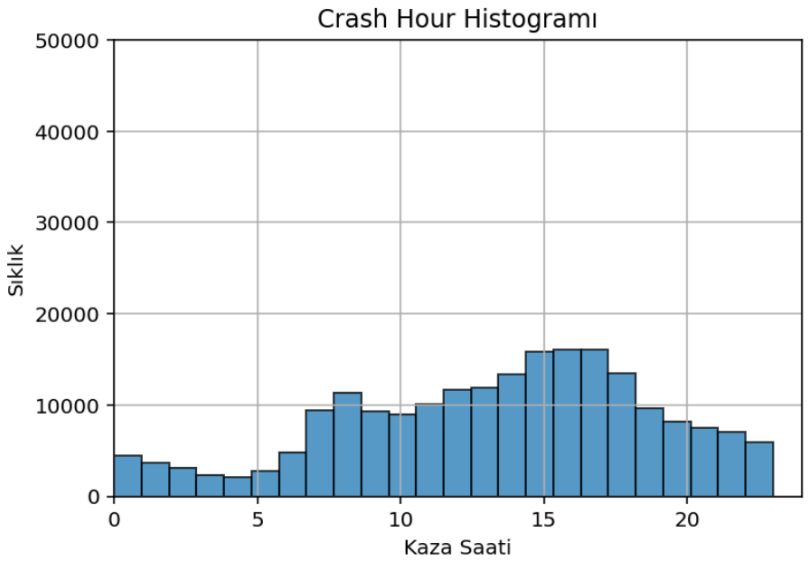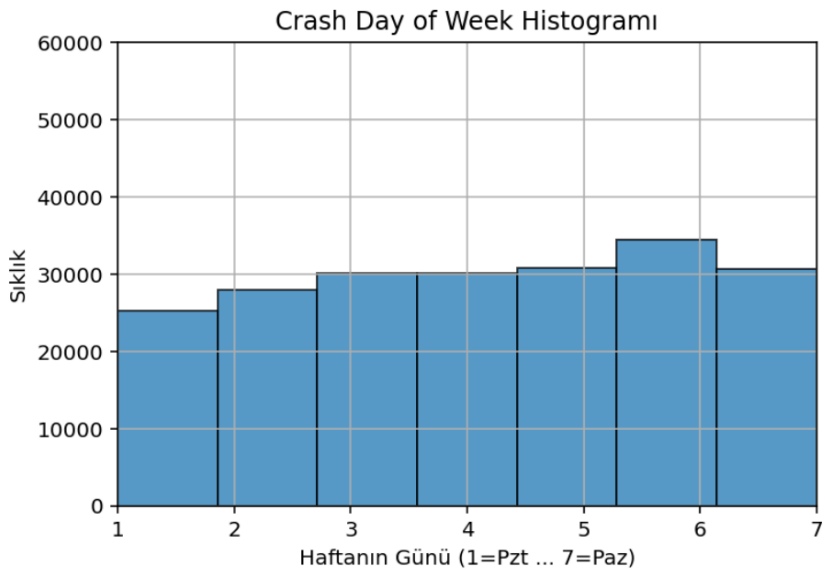
Histogramlar